1. 大数据简介

1.1 大数据的由来

随着计算机技术的发展,互联网的普及,信息的积累已经到了一个 非常庞大的地步,信息的增长也在不断的加快,随着互联网、物联网建 设的加快,信息更是爆炸式增长,收集、检索、统计这些信息越发困 难,必须使用新的技术来解决这些问题

1.2 什么是大数据

【1】定义

大数据指无法在一定时间范围内用常规软件工具进行捕捉、管理和 处理的数据集合,需要新处理模式才能具有更强的决策力、洞察发现力 和流程优化能力的海量、高增长率和多样化的信息资产

【2】总结

大数据是指即从各种各样类型的数据中,获得有价值的信息

1.3 大数据特性

【1】大体量(Volume)

数据体量大,一般从TB级别开始计算,可从数百TB到数十数百PB 甚至EB的规模

KB、MB、GB、TB、PB、EB、... ...

1KB = 1024Bytes

1MB = 1024K

1GB = 1024M

1TB = 1024G

1PB = 1024T

1EB = 1024P

.

【2】多样性(Variety)

数据的种类和来源多(多种异构数据源,数据库、爬虫、网络日志.....)

- 【3】时效性(Velocity) 很多大数据需要在一定的时间限度下得到及时处理
- 【4】准确性(Veracity) 处理的结果要保证一定的准确性
- 【5】大价值(Value)

大数据包含很多深度的价值,大数据分析挖掘和利用将带来巨大的 商业价值

【补充】

数据的价值密度越来越低,但是这并不意味着想要的数据越来越少,相反我们想要的数据是越来越多,但是样本总量的增长速度是要高于想要的数据的增长速度的

1.4 带来的问题

- 【1】数据存储问题 存储速度、存储空间
- 【2】数据计算|分析问题 性能与效率问题

1.5 大数据与Hadoop

- 【1】Hadoop是什么?
 - 1.1) Hadoop是一种分析和处理海量数据的软件平台
 - 1.2) Hadoop是一款开源软件,使用JAVA开发
 - 1.3) Hadoop可以提供一个分布式基础架构

2. Hadoop简介

2.1 Hadoop概述

2.1.1 Hadoop概念

定义

Hadoop是Yahoo!开发,后贡献给了Apache的一套开源的、可 靠的、可扩展的用于分布式计算的框架

Hadoop作者

Doug cutting

• Hadoop名字由来

以Hadoop作者的孩子的一个棕黄色的大象样子的玩具的命名



2.1.2 Hadoop特点

• 高可靠性

Hadoop按位存储和数据处理的能力值得信赖

• 高扩展性

Hadoop通过可用的计算机集群分配数据,完成存储和计算任务,这些集群可以方便地扩展到数以干计的节点中,具有高扩展性

• 高效性

Hadoop能够在节点之间进行动态地移动数据,并保证各个节点的动态平衡,处理速度非常快,具有高效性

• 高容错性

Hadoop能够自动保存数据的多个副本(默认是3个),并且能够自动将失败的任务重新分配

2.1.3 Hadoop能做什么

• 大数据量存储

分布式存储(各种云盘,百度,360~还有云平台均有hadoop应用)

• 日志处理

• 搜索引擎

如何存储持续增长的海量网页: 单节点 V.S. 分布式存储 如何对持续增长的海量网页进行排序: 超算 V.S. 分布式计算

• 数据挖掘

目前比较流行的广告推荐

2.1.4 Hadoop版本

• Hadoop1.0

包含Common, HDFS和MapReduce, 停止更新

• Hadoop2.0

包含了Common, HDFS, MapReduce和YARN。Hadoop2.0 和Hadoop1.0完全不兼容。

• Hadoop3.0

包含了Common, HDFS, MapReduce, YARN。Hadoop3.0 和Hadoop2.0是兼容的

2.2 Hadoop核心组件

2.2.1 HDFS (Hadoop Distributed File System)

HDFS

分布式存储,解决海量数据的存储

• HDFS特点及原理

HDFS具有扩展性、容错性、海量数量存储的特点 原理为将大文件切分成指定大小的数据块,并在分布式的多台机 器上保存多个副本

• HDFS角色和概念

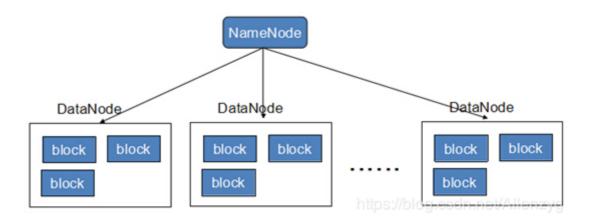
- 1. Client
 - 1.1 切分文件
 - 1.2 与namenode交互获取节点或文件元数据
 - 1.3 与datanode交互写入或读取数据
- 2. Namenode (master节点)
 - 2.1 存入文件元数据信息
 - 2.2 配置副本策略
 - 2.3 处理客户端的所有请求(读和写)
- 3. Secondarynode
 - 3.1 定期同步NameNode的元数据和日志信息,紧急情况下,可转正
- 4. Datanode (slave)

- 4.1 存储具体数据
- 4.2 汇报存储信息给namenode
- 5. Block

每块默认128MB大小

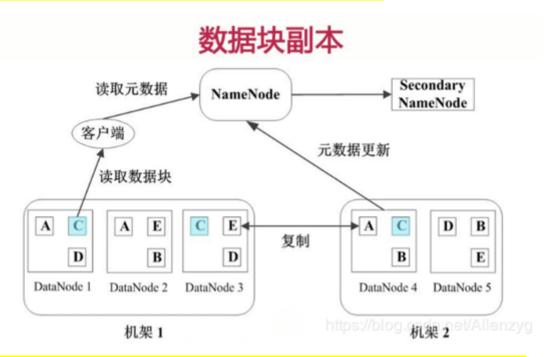
每块可以多个副本

• HDFS示意图



• HDFS原理图

1、每个数据块3个副本,分布在两个机架内的节点,2个副本在同一个机架上,另外一个副本在另外的机架上



<mark>2、心跳检测,datanode定期向namenode发送心跳消息。查</mark> 看是否有datanode挂掉了

心跳检测 Secondary 读取元数据 NameNode NameNode 客户端 心跳消息 心跳消息 心跳消息 A C \mathbf{C} C A **E** ◀ \mathbf{E} D A В

复制

 \mathbf{B}

https://blog.c:如架位/Allenzyg

DataNode 4

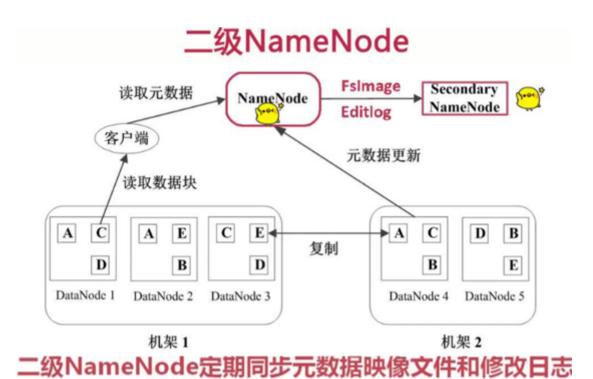
 \mathbf{E}

DataNode 5

3、secondary namenode;定期同步元数据映像文件和修改日 志,namenode发生故障,secondaryname会成为主 namenode

D

DataNode 3



NameNode发生故障时, 备胎转正©

• HDFS写文件流程

D

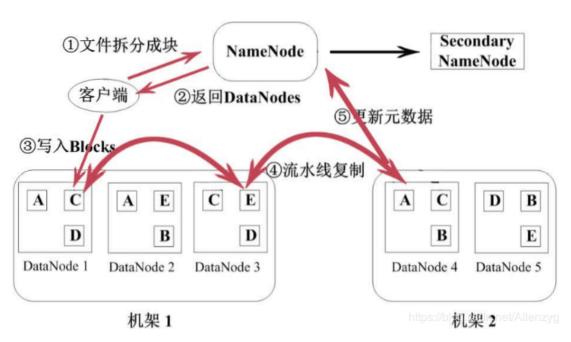
DataNode 1

 \mathbf{B}

DataNode 2

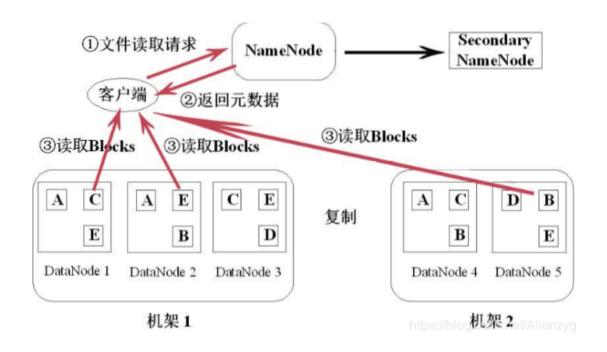
机架1

- 【1】客户端将文件拆分成固定大小128M的块,并通知namenode
- 【2】namenode找到可用的datanode返回给客户端
- 【3】客户端根据返回的datanode,对块进行写入
- 【4】通过流水线管道流水线复制
- 【5】更新元数据,告诉namenode已经完成了创建新的数据块,保证namenode中的元数据都是最新的状态



• HDFS读文件流程

- 【1】客户端向namenode发起读请求,把文件名,路径告诉namenode
- 【2】namenode查询元数据,并把数据返回客户端
- 【3】此时客户端就明白文件包含哪些块,这些块在哪些datanode 中可以找到

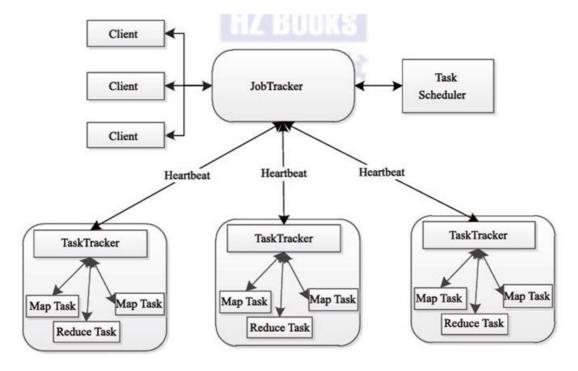


2.2.2 MapReduce

• MapReduce实现了分布式计算

Hadoop的MapReduce是对google三大论文的MapReduce的开源实现,实际上是一种编程模型,是一个分布式的计算框架,用于处理海量数据的运算,由JAVA实现

MapReduce原理图



• MapReduce角色及概念

1. JobTracker

- -Master节点只有一个
- -管理所有作业/任务的监控、错误处理等
- -将任务分解成一系列任务,并分派给TaskTracker

2. TaskTracker

- -Slave节点,一般是多台
- -运行Map Task和Reduce Task
- -并与JobTracker交互, 汇报任务状态

3. Map Task

-解析每条数据记录,传递给用户编写的map()并执行,将结果输出

4. Reducer Task

-从Map Task的执行结果中,远程读取输入数据,对数据进行排序,将数据按照分组传递给用户编写的reduce函数执行

2.2.3 Yarn

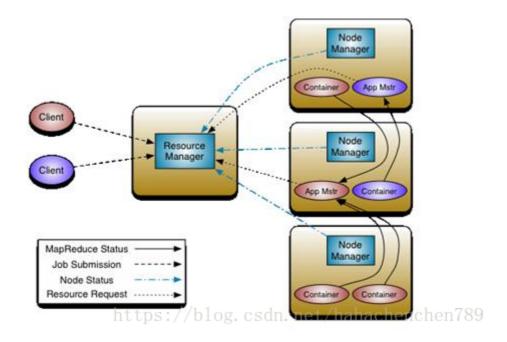
作用

负责整个集群资源的管理和调度,是Hadoop的一个通用的资源 管理系统

定义

Apache Hadoop YARN (Yet Another Resource Negotiator, 另一种资源协调者)是一种新的 Hadoop 资源管理器,它是一个通用资源管理系统,可为上层应用提供统一的资源管理和调度,它的引入为集群在利用率、资源统一管理和数据共享等方面带来了巨大好处

• 原理图



• Yarn角色及概念

- 1. Resourcemanager
 - -处理客户端请求
 - -启动/监控ApplicationMaster
 - -监控NodeManager
 - -资源分配与调度
- 2. Nodemanager
 - -单个节点上的资源管理
 - -处理来自ResourceManager的命令
 - -处理来自ApplicationMaster的命令
- 3. ApplicationMaster
 - -为应用程序申请资源,并分配给内部任务
 - -任务监控与容错
- 4. Container
 - -对任务运行行环境的抽象, 封装了CPU、内存等
- 5. Client

- -用户与Yarn交互的客户端程序
- -提交应用程序、监控应用程序状态,杀死应用程序等

2.3 Hadoop总结

2.3.1 Hadoop组成

- 1. 分布式存储 HDFS
- 2. 分布式计算 MapReduce+Yarn

2.3.2 HDFS特点

• HDFS优点

- 1. 高可靠性
- 2. 高扩展性
- 3. 高效性
- 4. 高容错性
- 5. 低成本:与一体机、商用数据仓库等相比,hadoop是开源的,项目的软件成本因此会大大降低

• HDFS缺点

- 1. 不能做到低延迟,对于低延迟数据访问,不适合hadoop
- 2. 不适合大量小文件存储,由于namenode将文件系统的元数据存储在内存中,因此该文件系统所能存储的文件总数受限于namenode的内存容量,根据经验,每个文件、目录和数据块的存储信息大约占150字节
- 3. 对于上传到HDFS上的文件,不支持修改文件,HDFS适合一次写入,多次读取的场景

2.3.3 HDFS相关

• 名词

- 1. NameNode
- 2. DataNode

• 写入文件流程

- 1. 客户端将文件拆分成固定大小128M的块,并通知 namenode
- 2. namenode找到可用的datanode返回给客户端
- 3. 客户端根据返回的datanode,对块进行写入
- 4. 通过流水线管道流水线复制
- 5. 更新元数据,告诉namenode已经完成了创建新的数据块, 保证namenode中的元数据都是最新的状态

• 读取文件流程

- 1. 客户端向namenode发起独立请求,把文件名,路径告诉 namenode
- 2. namenode查询元数据,并把数据返回客户端
- 3. 此时客户端就明白文件包含哪些块,这些块在哪些 datanode中可以找到

3. 环境安装

3.1 安装方式

• 单机模式

只能启动MapReduce

• 伪分布式

能启动HDFS、MapReduce 和 YARN的大部分功能

• 完全分布式

能启动Hadoop的所有功能

3.2 安装JDK

3.2.1 JDK安装步骤

1. 下载IDK安装包(下载Linux系统的.tar.gz 的安装包)

https://www.oracle.com/java/technologies/javase/javase-jdk 8-downloads.html

2. 更新Ubuntu源

sudo apt-get update

- 3. 将JDK压缩包解压到Ubuntu系统中 /usr/local/ 中 sudo tar -zxvf jdk-8u251-linux-x64.tar.gz -C /usr/local/
- 4. 将解压的文件夹重命名为 jdk8

cd /usr/local/

sudo mv jdk1.8.0_251/ jdk8

5. 添加到环境变量

cd /home/tarena/

sudo gedit .bashrc

在文件末尾添加如下内容:

export JAVA_HOME=/usr/local/jdk8

export JRE_HOME=\$JAVA_HOME/jre

export CLASSPATH=.:\$JAVA_HOME/lib:\$JRE_HOME/lib

export PATH=.:\$JAVA_HOME/bin:\$PATH

source .bashrc

6. 验证是否安装成功

java -version

<出现java的版本则证明安装并添加到环境变量成功 java version "1.8.0_251">

3.3 安装Hadoop并配置伪分布式

3.3.1 Hadoop安装配置步骤

1. 安装SSH

sudo apt-get install ssh

2. 配置免登录认证,避免使用Hadoop时的权限问题

ssh-keygen -t rsa (输入此条命令后一路回车)

cd ~/.ssh

cat id_rsa.pub >> authorized_keys

ssh localhost (发现并未让输入密码即可连接)

exit (退出远程连接状态)

3. 下载Hadoop 2.10 (374M)

https://archive.apache.org/dist/hadoop/common/hadoop-2. 10.0/hadoop-2.10.0.tar.gz

4. 解压到 /usr/local 目录中,并将文件夹重命名为 hadoop , 最后设置权限

sudo tar -zxvf hadoop-2.10.0.tar.gz -C /usr/local/

cd /usr/local

sudo mv hadoop-2.10.0/ hadoop2.10

sudo chown -R tarena hadoop2.10/

5. 验证Hadoop

cd /usr/local/hadoop2.10/bin

./hadoop version (此处出现hadoop的版本)

6. 设置JAVE_HOME环境变量

sudo gedit /usr/local/hadoop2.10/etc/hadoop/hadoop-env.sh

把原来的export JAVA_HOME=\${JAVA_HOME}改为 export JAVA_HOME=/usr/local/jdk8

7. 设置Hadoop环境变量

sudo gedit /home/tarena/.bashrc

在末尾追加

```
export HADOOP_HOME=/usr/local/hadoop2.10
export CLASSPATH=.:
{JAVA_HOME}/lib:${HADOOP_HOME}/sbin:$PATH
export
PATH=.:${HADOOP_HOME}/bin:${HADOOP_HOME}/sbin:$PA
TH
```

source /home/tarena/.bashrc

- 8. 伪分布式配置,修改2个配置文件 (core-site.xml 和 hdfs-site.xml)
- 9. 修改core-site.xml sudo gedit /usr/local/hadoop2.10/etc/hadoop/core-site.xml 添加如下内容

10. 修改hdfs-site.xml

sudo gedit /usr/local/hadoop2.10/etc/hadoop/hdfs-site.xml 添加如下内容

```
<configuration>
   cproperty>
        <!--副本数量-->
        <name>dfs.replication</name>
        <value>1</value>
   </property>
   cproperty>
        <!--namenode数据目录-->
        <name>dfs.namenode.name.dir</name>
<value>file:/usr/local/hadoop2.10/tmp/dfs/name
value>
   </property>
   cproperty>
        <!--datanode数据目录-->
        <name>dfs.datanode.data.dir</name>
<value>file:/usr/local/hadoop2.10/tmp/dfs/data
value>
   </property>
</configuration>
```

11. 配置YARN - 1

添加如下配置

cd /usr/local/hadoop2.10/etc/hadoop cp mapred-site.xml.template mapred-site.xml sudo gedit mapred-site.xml

```
<name>mapreduce.framework.name
```

12. 配置YARN - 2

sudo gedit yarn-site.xml

添加如下配置:

```
<name>yarn.nodemanager.aux-services
```

13. 执行NameNode格式化

cd /usr/local/hadoop2.10/bin

./hdfs namenode -format

出现 Storage directory /usr/local/hadoop2.10/tmp/dfs/name has been successfully formatted 则表示格式化成功

14. 启动Hadoop所有组件

cd /usr/local/hadoop2.10/sbin

./start-all.sh

启动时可能会出现警告,直接忽略即可,不影响正常使用

15. 启动成功后,可访问Web页面查看 NameNode 和 Datanode 信息,还可以在线查看 HDFS 中的文件

http://localhost:50070

16. 查看Hadoop相关组件进程

jps

会发现如下进程

NameNode

DataNode

SecondaryNameNode

ResourceManager

NodeManager

17. 测试 - 将本地文件上传至hdfs

hadoop fs -put 一个本地的任意文件 /

hadoop fs -ls /

也可以在浏览器中Utilities->Browse the file system查看

4. HDFS Shell操作

4.1 命令格式

hadoop fs -命令

4.2 常用命令汇总

• 查看HDFS系统目录(Is)

命令格式:hadoop fs -ls 路径

示例: hadoop fs-ls/

• 创建文件夹 (mkdir)

命令格式1:hadoop fs -mkdir 绝对路径

命令格式2: hadoop fs-mkdir-p 绝对路径 (可递归创建文

件夹)

示例1: hadoop fs -mkdir /test

示例2 : hadoop fs -mkdir -p /test/stu

• 上传文件 (put)

命令格式:hadoop fs-put 本地文件 HDFS目录

示例:hadoop fs -put words.txt /test/

• 下载文件 (get)

命令格式:hadoop fs -get HDFS文件 本地目录

示例: hadoop fs -get /test/words.txt /home/tarena/

• 删除文件或目录 (rm)

命令格式1:hadoop fs -rm 文件或目录的绝对路径

命令格式2: hadoop fs-rm-r 目录 (删除文件夹要加-r选

项)

示例1: hadoop fs -rm /test/words.txt

示例2:hadoop fs -rm -r /test

• 查看文件内容(text)

命令格式: haddop fs-text 文件绝对路径

示例: hadoop fs -text /test/words.txt

• 移动(mv)

命令格式:hadoop fs-mv 源文件 目标目录

示例: hadoop fs -mv /test/words.txt /words.txt

• 复制 (cp)

命令格式: hadoop fs-cp 源文件 目标目录

示例:hadoop fs -cp /test/words.txt /words.txt

4.3 HDFS Shell操作练习

- 1. 在本地 /home/tarena/ 下新建 students.txt touch /home/tarena/students.txt
- 2. 在students.txt中任意添加内容 Twink Twink little star How I wonder what you are
- 3. 在HDFS中创建 /studir/stuinfo/ 目录 hadoop fs -mkdir -p /studir/stuinfo/
- 4. 将本地students.txt文件上传到HDFS中

hadoop fs -put /home/tarena/students.txt /studir/stuinfo/

- 5. 查看HDFS中 /studir/stuinfo/students.txt 的内容 hadoop fs -text /studir/stuinfo/students.txt
- 6. 删除HDFS中的 /studir 目录 hadoop fs -rm -r /studir